📊 ANÁLISIS COMPLETO DEL DATASET — NHANES DEMO_L (2021-2023)

¿Qué es? Es una encuesta nacional de salud y nutrición de EE.UU. (CDC). Tiene **11,933 participantes** y **28 columnas**. El archivo se descarga como .xpt (formato SAS), así que en Colab usaremos pyreadstat o pandas con xport.

🔵 COLUMNAS — qué es cada una

Identificadores / administrativos (NO se usan como features):

- SEQN → Número de secuencia del participante. Es solo un ID único, no aporta nada al modelo.
- SDDSRVYR → Ciclo de publicación. Todos tienen valor "12" (este ciclo). Sin variación = inútil para el modelo.
- RIDSTATR → Si fue solo entrevistado (1) o también examinado físicamente (2). Útil para filtrar, no como feature.
- RIDEXMON → Semestre del año en que fue examinado (1=nov-abr, 2=may-oct). Podría usarse pero tiene 3073 nulos (los no examinados).
- WTINT2YR / WTMEC2YR → Pesos de muestreo estadístico del CDC. Son para análisis poblacional complejo, NO para redes neuronales. Se descartan.
- SDMVSTRA / SDMVPSU → Unidades de varianza enmascarada. Solo para cálculos de varianza del diseño muestral. Se descartan.

Variables del participante individual (las más importantes):

- RIAGENDR → Género: 1=Hombre, 2=Mujer. Sin nulos.
- RIDAGEYR → Edad en años (0–79, los de 80+ están todos codificados como 80). Sin nulos.
- RIDAGEMN → Edad en meses, solo para bebés 0–24 meses. Tiene 11,556 nulos (todos los demás). Se descarta (ya tenemos edad en años).
- RIDRETH1 → Raza/Origen hispano (5 categorías). Sin nulos.
- RIDRETH3 → Igual que RIDRETH1 pero separando asiáticos (6 categorías). Más detallado. Usaremos este y descartamos RIDRETH1 para no tener info duplicada.
- RIDEXAGM → Edad en meses al examen, solo para menores de 19 años. 9,146 nulos. Se descarta (ya tenemos edad en años).
- RIDEXPRG → Estado de embarazo en el examen (solo mujeres 20–44 años). 10,430 nulos. Se descarta por los nulos masivos.
- DMQMILIZ → ¿Sirvió en las fuerzas armadas? (1=Sí, 2=No). Solo aplica desde 17 años, 3,632 nulos. Se incluye imputando la moda.

- DMDBORN4 → País de nacimiento: 1=EE.UU., 2=Otro. Solo 19 nulos. Se usa.
- DMDYRUSR → Años viviendo en EE.UU. (categorías 1–6). Solo aplica para nacidos fuera, 10,058 nulos. Se descarta.
- DMDEDUC2 → Nivel educativo adultos 20+. 5 niveles (1=sin secundaria, 5=universitario). 4,139 nulos (los menores de 20). Se incluye imputando mediana.
- DMDMARTZ → Estado civil adultos 20+ (1=casado/pareja, 2=viudo/divorciado, 3=soltero). 4,141 nulos (menores de 20). Se incluye imputando moda.
- DMDHHSIZ → Número de personas en el hogar (1–7+). Sin nulos. Se usa.
- INDFMPIR → Relación ingreso familiar / línea de pobreza (0 a 5+). 2,041 nulos. Se incluye imputando mediana.

Variables del jefe de hogar (solo para participantes 0–19 años):

- DMDHRGND → Género del jefe de hogar. 7,818 nulos. Se descarta.
- DMDHRAGZ → Edad del jefe de hogar (categorías). 7,809 nulos. Se descarta.
- DMDHREDZ → Educación del jefe de hogar. 8,187 nulos. Se descarta.
- DMDHRMAZ → Estado civil del jefe de hogar. 7,913 nulos. Se descarta.
- DMDHSEDZ → Educación del cónyuge del jefe de hogar. 9,806 nulos. Se descarta.

🎯 ¿QUÉ PREDECIMOS?

Variable objetivo: INDFMPIR convertida a binaria → ¿Está por debajo de la línea de pobreza?

- INDFMPIR < 1.0 → **Clase 1: En pobreza** (el ingreso familiar no alcanza la línea de pobreza)
- INDFMPIR >= 1.0 → **Clase 0: No en pobreza**

¿Por qué esta variable? Porque es la única variable continua que refleja situación socioeconómica real, y tiene sentido predecirla con datos demográficos (edad, género, raza, educación, tamaño del hogar). Es un problema clásico de clasificación binaria, igual al doc 2 (partículas señal/fondo). Tiene algo de desbalance de clases que manejaremos.

✅ FEATURES FINALES QUE USAREMOS (7 columnas)

Feature	Descripción	Nulos	Tratamiento
RIAGENDR	Género	0	Directo
RIDAGEYR	Edad en años	0	Directo

Feature	Descripción	Nulos	Tratamiento
RIDRETH3	Raza/Etnia (6 categorías)	0	Directo
DMDBORN4	País de nacimiento	19	Imputar moda
DMDEDUC2	Nivel educativo	4,139	Imputar mediana
DMDMARTZ	Estado civil	4,141	Imputar moda
DMDHHSIZ	Tamaño del hogar	0	Directo

Target: INDFMPIR → binarizada (los 2,041 nulos de INDFMPIR se eliminan directamente, ya que sin el target no hay ejemplo válido).