1️⃣ ¿QUÉ PROBLEMA ES?

Este dataset sirve para responder:

¿Una persona gana más de 50K dólares al año?

Por lo tanto:

Tipo de problema

Clasificación binaria

Clases:

<=50K
>50K

Entonces el modelo aprenderá algo como:

edad = 45
educación = master
ocupación = manager
horas_trabajo = 50

→ probable >50K

2️⃣ TAMAÑO DEL DATASET

adult.data tiene aproximadamente:

32561 filas
14 columnas + 1 target

Cada fila representa **una persona**.

3️⃣ COLUMNAS DEL DATASET

Orden real de las columnas:

1 age
2 workclass
3 fnlwgt
4 education
5 education-num
6 marital-status
7 occupation
8 relationship
9 race

10 sex
11 capital-gain
12 capital-loss
13 hours-per-week
14 native-country
15 income

4️⃣ EXPLICACIÓN DE CADA COLUMNA

1️⃣ age

Edad de la persona.

Ejemplo:

39
50
28

Tipo:

numérico entero

2️⃣ workclass

Tipo de empleo.

Ejemplos:

Private
Self-emp-not-inc
State-gov
Federal-gov
Local-gov
Without-pay
Never-worked

Tipo:

categórico

3️⃣ fnlwgt

Peso estadístico usado por el censo.

Sirve para ajustar la muestra a la población real.

Ejemplo:

77516
83311
215646

Tipo:

numérico

⚠️ En muchos modelos **no se usa** porque no describe a la persona.

4️⃣ education

Nivel educativo.

Ejemplos:

Bachelors
HS-grad
Masters
Doctorate
Some-college

Tipo:

categórico

5️⃣ education-num

La **misma educación pero codificada en número**.

Ejemplo:

Bachelors → 13
HS-grad → 9
Masters → 14

Tipo:

numérico

⚠️ Duplica información de **education**.

Generalmente usamos **solo education-num**.

6️⃣ marital-status

Estado civil.

Ejemplos:

Never-married
Married-civ-spouse
Divorced
Separated
Widowed

Tipo:

categórico

7️⃣ occupation

Tipo de trabajo.

Ejemplos:

Tech-support
Craft-repair
Sales
Exec-managerial
Handlers-cleaners

Tipo:

categórico

8️⃣ relationship

Relación familiar.

Ejemplos:

Husband
Wife
Own-child
Not-in-family
Unmarried

Tipo:

categórico

9️⃣ race

Raza.

Ejemplos:

White
Black
Asian-Pac-Islander
Amer-Indian-Eskimo
Other

Tipo:

categórico

🔟 sex

Sexo.

Valores:

Male
Female

Tipo:

categórico binario

---

1 1️⃣ capital-gain

Ganancias de capital.

Ejemplo:

0
14084
5178

Tipo:

numérico

---

1 2️⃣ capital-loss

Pérdidas de capital.

Tipo:

numérico

---

1 3 hours-per-week

Horas trabajadas por semana.

Ejemplo:

40
50
20

Tipo:

numérico

---

1 4 native-country

País de origen.

Ejemplos:

United-States
Mexico
Philippines
Germany
India

Tipo:

categórico

---

1 5 income (TARGET)

Variable objetivo.

Valores:

<=50K
>50K

La convertiremos a:

0 = <=50K
1 = >50K

5️⃣ VALORES NULOS

En este dataset los nulos aparecen como:

?

Aparecen en:

workclass
occupation
native-country

Entonces debemos:

reemplazar ? → NaN

y luego imputar con:

moda

porque son variables categóricas.

6️⃣ VARIABLES QUE USAREMOS

Usaremos casi todas.

Pero eliminaremos:

education

porque **education-num ya la representa**.

---

fnlwgt

porque es **peso estadístico**, no característica real.

7️⃣ FEATURES FINALES

Usaremos:

age
workclass
education-num
marital-status
occupation
relationship
race
sex

capital-gain
capital-loss
hours-per-week
native-country

Target:

income