1️⃣ ¿QUÉ PROBLEMA ES ESTE DATASET?

Este dataset intenta responder:

¿Una persona debe recibir aprobación de crédito o no?

Por lo tanto:

Tipo de problema

Clasificación binaria

Clases:

+ → crédito aprobado
- → crédito rechazado

Entonces el modelo aprenderá algo como:

edad alta
buen historial
ingresos altos

→ aprobar crédito

2️⃣ TAMAÑO DEL DATASET

El archivo **crx.data** contiene aproximadamente:

690 filas
16 columnas

Las primeras **15 columnas son variables** y la última es **la variable objetivo**.

3️⃣ COLUMNAS DEL DATASET

En el dataset las columnas se llaman:

A1
A2
A3
A4
A5
A6
A7
A8
A9
A10

A11
A12
A13
A14
A15
A16

Pero en realidad representan características financieras.

4️⃣ EXPLICACIÓN DE CADA COLUMNA

A1

Tipo:

categórica binaria

Valores:

a
b

Probablemente representa **sexo o tipo de cliente**.

A2

Tipo:

numérico continuo

Representa algo como:

edad del solicitante

Ejemplo:

30.83
58.67
24.5

A3

Tipo:

numérico continuo

Representa **cantidad financiera** (posiblemente deuda o ingreso).

Ejemplo:

0
13.75
5.0

A4

Tipo:

categórico

Valores posibles:

u
y
l
t

Probablemente **estado civil o categoría financiera**.

A5

Tipo:

categórico

Valores:

g
p
gg

Relacionado con **tipo de solicitud o garantía**.

A6

Tipo:

categórico

Valores como:

c
d
cc
i
j

k
m
r
q
w
x

Probablemente **ocupación o tipo de empleo**.

A7

Tipo:

categórico

Valores como:

v
h
bb
j
n
z

Probablemente **tipo de residencia o historial crediticio**.

A8

Tipo:

numérico continuo

Ejemplo:

1.25
3.04
0

Puede representar **tiempo de crédito o saldo**.

A9

Tipo:

binario categórico

Valores:

t
f

Ejemplo:

t → true
f → false

A10

Tipo:

binario categórico

Valores:

t
f

Relacionado con **historial de crédito**.

A11

Tipo:

numérico entero

Ejemplo:

0
1
5

Probablemente número de **créditos previos**.

A12

Tipo:

binario categórico

Valores:

t
f

A13

Tipo:

categórico

Valores:

g
p
s

Relacionado con **tipo de cliente o garantía**.

A14

Tipo:

numérico entero

Ejemplo:

0
100
560

Probablemente **ingreso o límite de crédito**.

A15

Tipo:

numérico entero

Ejemplo:

0
500
1200

Relacionado con **balance financiero**.

A16 (TARGET)

Variable objetivo.

Valores:

+
-

Significado:

+ → crédito aprobado
- → crédito rechazado

La convertiremos a:

1 → aprobado
0 → rechazado

5️⃣ VALORES NULOS

En este dataset los valores faltantes aparecen como:

?

Aparecen en varias columnas como:

A1
A2
A4
A5
A6
A7
A14

Entonces debemos:

? → NaN

Luego imputar.

6️⃣ ¿EL DATASET ESTÁ DESBALANCEADO?

Aproximadamente:

55% aprobados
45% rechazados

Está **bastante balanceado**, así que **no es necesario balancearlo**.

7️⃣ VARIABLES QUE USAREMOS

Usaremos **todas las variables** excepto la última que es el target.

No eliminaremos columnas porque todas aportan información.

8️⃣ TARGET

A16

Lo convertiremos:

+ → 1
- → 0